GAN(Generative Adversarial Networks)

에이아이스쿨(AISchool) 대표
양진호 (솔라리스)
http://aischool.ai
http://solarisailab.com

생성 모델(Generative Model)의 개념

- 지금까지 주로 살펴본 모델들은 지도 학습 방법론으로 어떤 값을 분류하거나 예측하는데 초점이 맞추어져 있었습니다. 이런 모델을 **구분 모델**Discriminative Model이라고 합니다. 이번 시간에 배울 **생성 모델**Generative Model은 조금 다른 목적을 가지고 있습니다. 생성 모델은 주어진 트레이닝 데이터의 특징을 학습하여 트레이닝 데이터와 유사한 새로운 데이터를 생성Generate하는데 그 목적이 있습니다.
- 이런 과정을 좀 더 수학적인 용어로 표현하면 생성 모델의 목적은 **트레이닝 데이터의 분포를 학습**하여 트레이닝 데이터의 분포와 유사한 데이터를 샘플링을 통해 새로 생성하는 것입니다. 그림은 생성 모델의 학습 과정을 보여줍니다. 생성 모델은 트레이닝 데이터의 분포인 $p_{data}(x)$를 통해 유사한 분포인 $p_{model}(x)$를 학습합니다.

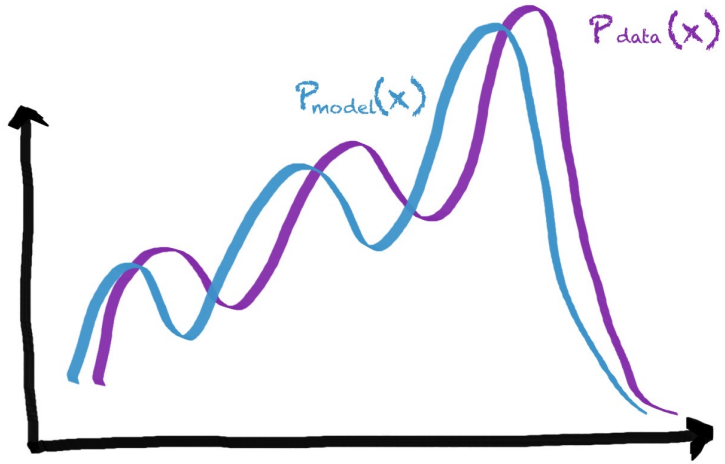

잠재 변수(Latent Variable)

- 생성 모델의 개념을 자세히 이해하기 위해서는 몇 가지 확률 통계학의 개념들을 이해해야만 합니다. 먼저 **잠재 변수**Latent Variable라는 개념을 살펴봅시다.
- 잠재 변수는 이름에서 알 수 있듯이 숨겨진 변수로써 데이터에 직접적으로 나타나지 않지만 현재 **데이터 분포를 만드는데 영향을 끼치는 변수**입니다. 따라서 어떤 데이터의 잠재 변수를 알아내면 잠재 변수를 이용해서 해당 데이터와 유사한 데이터를 생성해낼 수 있습니다.
- 즉, 잠재 변수는 데이터의 형태를 결정하는 특징으로 생각할 수 있습니다. 잠재 변수는 보통 잠재 변수로부터 생성하는 데이터보다 적은 차원을 갖습니다. 그림은 우리가 가지고 있는 데이터 x와 잠재 변수 z로부터 생성된 다양한 데이터 x를 보여줍니다.

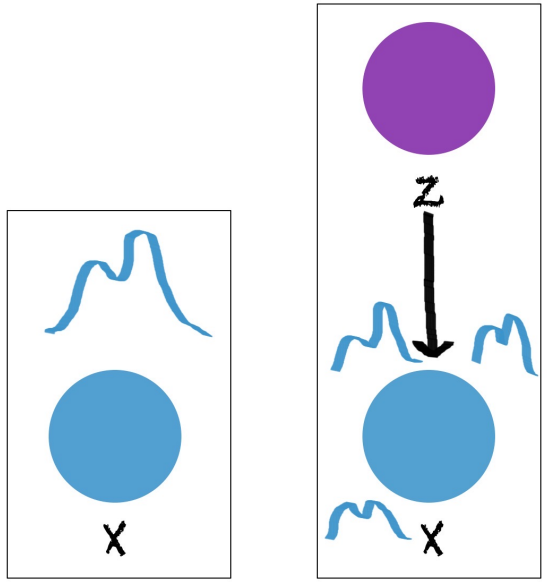

생성 모델(Generative Model)의 개념

- 예를 들어서, 우리가 학습하고 생성하고자 하는 데이터가 **사람 얼굴 이미지**라면 적절한 잠재 변수는 사람의 성별이 될 수 있습니다. 잠재 변수를 **사람의 성별**로 간주할 경우, 이 사람이 남자인지 여자인지를 나타내는 **1차원 Boolean 특징값**만을 가지고도 생성하고자 하는 데이터의 형태(예를 들어, 남자라면 짧은 머리의 얼굴, 여자라면 긴머리의 얼굴)를 어느 정도 결정할 수 있습니다. 이에 더해서 **사람의 표정, 촬영한 카메라의 각도 등**이 적절한 잠재 변수가 될 수 있을 것입니다.
- 다른 예로 우리가 학습하고 생성하고자하는 데이터가 **MNIST 필기체 데이터**라면 **필기획의 기울기, 이미지를 나타내는 레이블(1,2,3,...)** 등이 적절한 잠재 변수가 될 수 있습니다.
- 다음 장에서 배우는 GAN은 **임의의(노이즈의) 잠재 변수**로부터 **적절한 데이터를 생성해내는 함수**를 학습합니다. 즉, GAN의 동작 과정을 수식으로 나타내면 아래와 같습니다.

$$x_{data} = f_{GAN}(z_{noise})$$

GAN(Generative Adversarial Networks)의 개념

- **GAN**Generative Adversarial Networks은 게임 이론Game Theory의 minimax two-player 게임의 구조를 이용해서 생성 모델을 구현한 구조입니다. GAN 모델은 Goodfellow, Ian, et al의 "Generative adversarial nets."라는 제목의 2014년도 논문에서 최초로 제안 되었습니다.
- 구체적으로 GAN은 **생성자**Generator와 **구분자**Discriminator라는 2가지 부분으로 구성되어 있습니다.
- GAN의 개념을 직관적으로 이해하기 위해서 많이 사용하는 예시는 **경찰(구분자)**과 **위조지폐 생성범(생성자)**입니다. 위조지폐 생성범은 경찰을 속이기 위해서 최대한 진짜 지폐와 구분이 되지않는 위조지폐를 생성하려고 노력할 것입니다. 이에 반해 경찰은 위조지폐 생성범이 생성한 위조지폐와 진짜 지폐를 최대한 정확하게 구분할 수 있도록 노력할 것입니다.
- 경찰과 위조지폐 생성범이 서로 노력해서 계속 학습을 진행하면 경찰이 위조지폐 생성범이 생성한 위조지폐와 진짜 지폐를 50% 확률로 구분할 수 있게 되는 균형점에서 학습이 종료됩니다. 결과적으로 **생성자는 원본 데이터와 유사한 데이터 분포를 학습**하게됩니다.

GAN(Generative Adversarial Networks)의 구조

- 사람 얼굴 이미지를 생성하는 GAN을 구성할 경우, 생성자 G는 임의의 잠재 변수(노이즈값)을 입력 받아서 가짜 이미지$_{\text{Fake Image}}$를 생성합니다.
- 구분자 D는 진짜 사람 얼굴 이미지인 진짜 이미지와 가짜 이미지를 입력 받을 수 있고, 만약 입력 받은 이미지가 진짜 이미지이면 1, 가짜 이미지이면 0의 값을 출력하는 것을 목표로 합니다.
- 생성자 G와 구분자 D는 임의의 머신 러닝 모델(예를 들면, 소프트맥스 회귀, SVM 등)을 사용하여 구현할 수 있지만 일반적으로는 인공신경망을 이용해서 구현합니다.

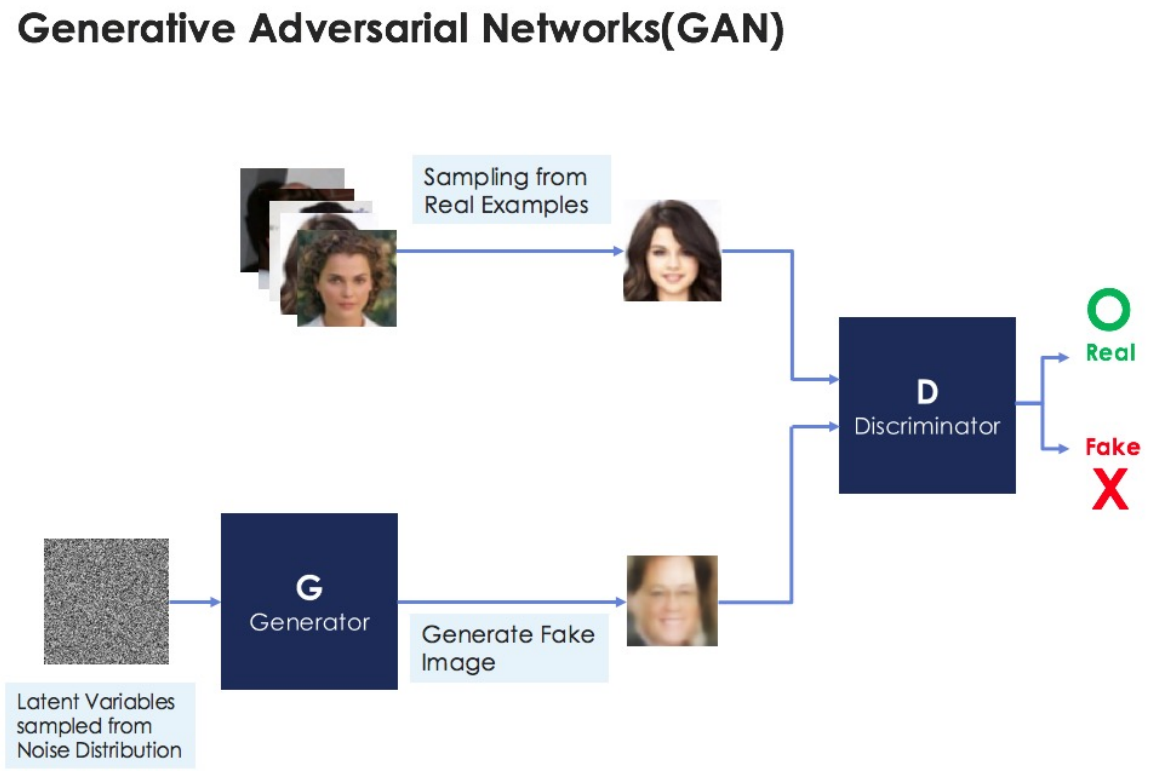

GAN의 Loss Function

- We train D to maximize the probability of assigning the correct label to both training examples and samples from G.
- We simultaneously train G to minimize log(1 - D(G(z))).
- In other words, D and G play the following two-player minimax game with value function V(G,D):

$$\min_G \max_D V(D,G) = \mathbb{E}_{\boldsymbol{x}\sim p_{\text{data}}(\boldsymbol{x})}[\log D(\boldsymbol{x})] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}(\boldsymbol{z})}[\log(1 - D(G(\boldsymbol{z})))].$$

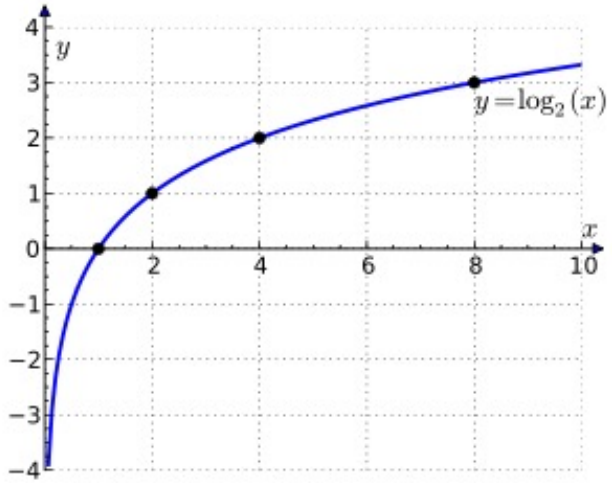

GAN Learning Algorithm

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k, is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

  for k steps **do**

  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Sample minibatch of m examples $\{\boldsymbol{x}^{(1)}, \ldots, \boldsymbol{x}^{(m)}\}$ from data generating distribution $p_{\text{data}}(\boldsymbol{x})$.
  - Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} \left[\log D\left(\boldsymbol{x}^{(i)}\right) + \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right) \right].$$

  end for

  - Sample minibatch of m noise samples $\{\boldsymbol{z}^{(1)}, \ldots, \boldsymbol{z}^{(m)}\}$ from noise prior $p_g(\boldsymbol{z})$.
  - Update the generator by descending its stochastic gradient:

$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^{m} \log\left(1 - D\left(G\left(\boldsymbol{z}^{(i)}\right)\right)\right).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

GAN(Generative Adversarial Networks)의 동작과정

- 그림은 GAN의 학습 과정을 단계별로 나타냅니다.
- 학습 초기에는 트레이닝 데이터의 분포(검은색 점)과 다른 형태로 생성자가 분포를 생성합니다. 또한 구분자(파란색 라인)는 임의의 확률로 트레이닝 데이터와 생성한 데이터를 구분합니다.
- 그리고 잠재 **변수 z의 값은 임의의 데이터 값 x로 맵핑**됩니다. 하지만 학습이 진행됨에 따라 생성자가 생성한 분포(초록색 라인)는 트레이닝 데이터의 분포와 점점 유사해지다가 **학습이 완료되면 트레이닝 데이터의 분포와 일치**하게 됩니다.
- 또한 구분자는 50% 확률로 트레이닝 데이터와 생성자가 생성한 가짜 데이터를 구분하게 되고, 잠재 변수 z의 값은 트레이닝 데이터의 분포값 x로 맵핑되게 됩니다.

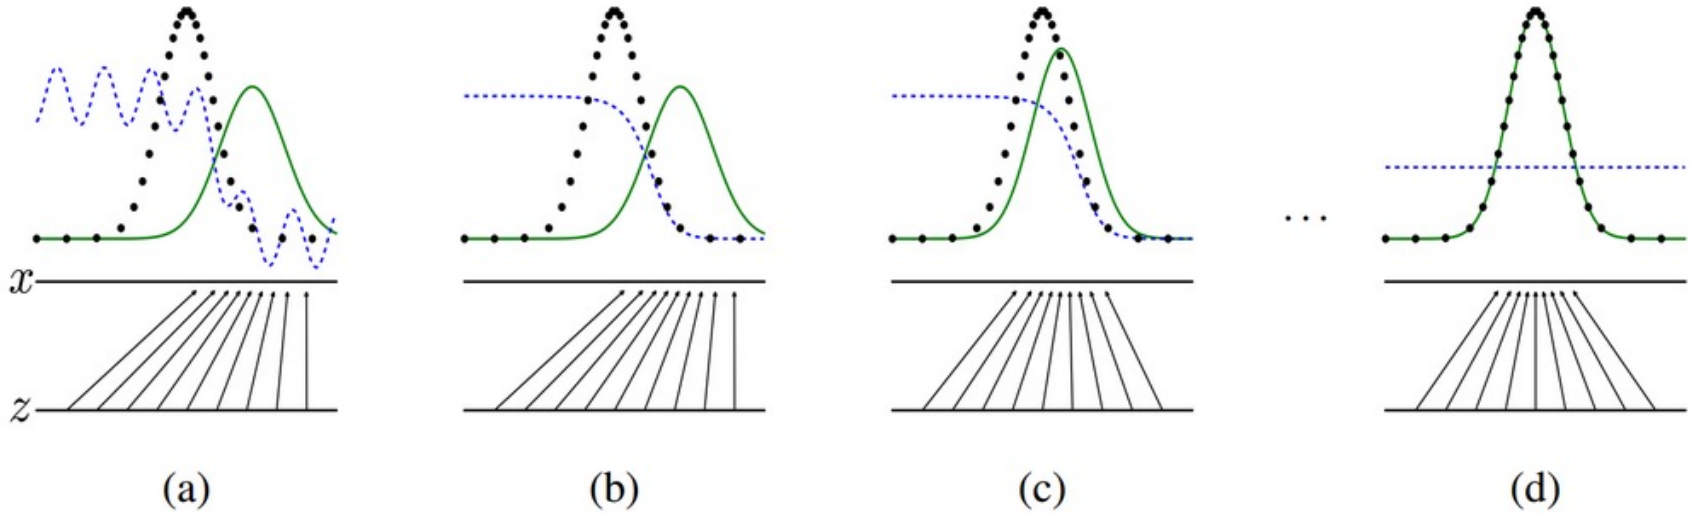

GAN의 장단점

1. VAE는 데이터 분포에 대한 일종의 가정(Gaussian Distribution)을 포함하고 있지만 GAN은 순수하게 데이터로부터 데이터 분포를 학습한다.
2. VAE는 Inference P(z|x)를 구할수 있지만 GAN은 그럴 수 없다.
3. 일반적으로 GAN이 더 성능이 좋다.(Blur가 더 적다.)

GAN을 이용한 MNIST 데이터 생성

- 이제 MNIST 데이터의 분포를 학습하고 새로운 MNIST 데이터를 생성하는 GAN 모델을 구현해봅시다.
- https://github.com/solaris33/deep-learning-tensorflow-book-code/blob/master/Ch11-GAN/mnist_gan.py
- 코드를 실행하고 나서 generated_output 폴더에 들어가면, 각 반복마다 GAN이 생성하는 MNIST 이미지를 볼 수 있습니다. 학습이 모두 끝나면 최종적으로 그림과 같이 그럴듯한 MNIST 이미지를 생성해내는 모습을 볼 수 있습니다.

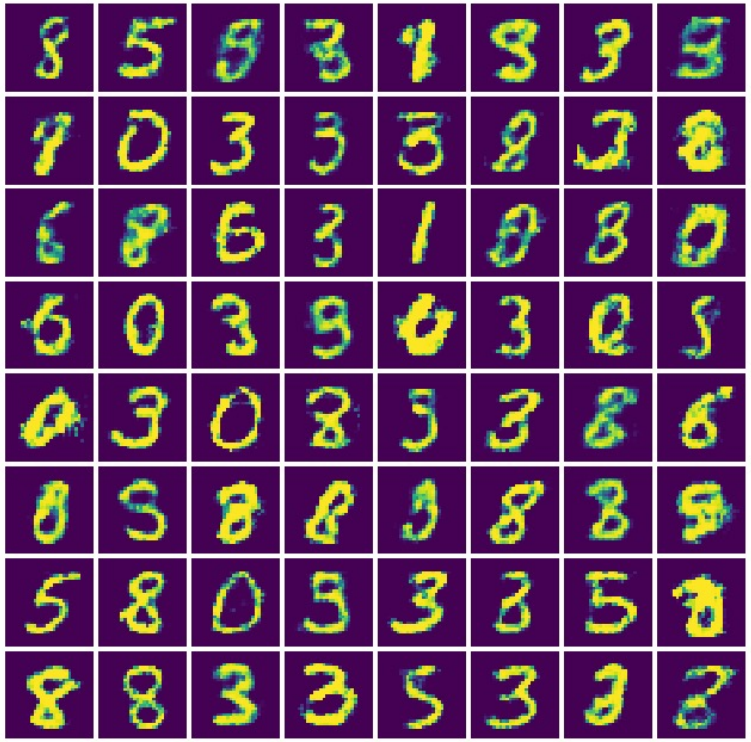

Thank you!